TEORIA DA COMPUTAÇÃO E COMPILADORES

Análise Léxica

Prof. Dr. Fernando Kakugawa

fernando.kakugawa@animaeducacao.com.br



- Papel do analisador léxico:
 - ler o arquivo fonte em busca de unidades significativas (tokens) instanciadas por lexemas ou átomos
- Também denominado de scanner, porque varre o arquivo de entrada eliminando comentários e caracteres indesejáveis ao agrupar caracteres com um papel bem definido

- A separação da análise léxica da análise sintática facilita o projeto e torna o compilador mais eficiente e portável
- Um analisador léxico executa tarefas como:
 - 1. contar as linhas de um programa
 - 2. eliminar comentários
 - 3. contar a quantidade de caracteres de um arquivo
 - 4. tratar espaços

- Tokens são padrões de caracteres com um significado específico em um código fonte
 - Definida por um alfabeto e um conjunto de definições regulares
- Lexemas são ocorrências de um token em um código fonte, também são chamados de átomos por alguns autores

- Um mesmo token pode ser produzido por várias cadeias de entradas
- Tal conjunto de cadeias é descrito por uma regra denominada padrão, associada a tais tokens
- O padrão reconhece as cadeias de tal conjunto, ou seja, reconhece os *lexemas* que são padrão de um *token*

- Usualmente os padrões são convenções determinadas pela linguagem para formação de classes de tokens
 - identificadores: letra seguida por letras ou dígitos
 - literal: cadeias de caracteres delimitadas por aspas
 - num: qualquer constante numérica

- Os tokens usualmente são conhecidos pelo seu lexema (sequência de caracteres que compõe um único token) e atributos adicionais
- Os *tokens* podem ser entregues ao *parser* como tuplas na forma <a, b, ..., n> assim a entrada:
 - a = b + 3
- poderia gerar as tuplas:
 - <id,a> <=, > <id,b> <op_arit,+ > <num,3>
 - note que alguns tokens não necessitam atributos adicionais

- A declaração C seguinte;
 - int k = 123;
- Possui várias subcadeias:
 - int é o *lexema* para um *token* tipo palavrareservada.
 - k é o lexema para um *token* tipo identificador
 - = é o lexema para um token tipo operador de atribuição
 - 123 é o lexema para um *token* tipo número literal cujo atributo valor é 123
 - ; é o lexema para um *token* tipo pontuação

 Quais os tokens que podem ser reconhecidos em uma linguagem de programação como C ?

| palavras reservadas | if else while do |
|------------------------|------------------|
| identificadores | it eise white do |
| operadores relacionais | < > <= >= != |
| operadores aritméticos | + * / - |
| operadores lógicos | && & ! |
| operador de atribuição | = |
| delimitadores | · , |
| caracteres especiais | ()[]{} |

 Quais os tokens que podem ser reconhecidos em uma linguagem de marcação como HTML?

```
Tags <html> <body> ...
```

Comentários <!-- ... -->

Conteúdos Página de teste...

Especiais é

- Lexemas podem ter atributos como número da linha em que se encontra no código fonte e o valor de uma constante numérica ou um literal
- Normalmente utiliza-se um único atributo que é um apontador para a Tabela de Símbolos que armazena essas informações em registros

- O analisador léxico simplesmente varre a entrada (arquivo fonte) em busca de padrões pertencentes a uma linguagem.
- Possibilidade de ocorrer erro:
 - aparecer um caractere que n\u00e3o pertence ao alfabeto da linguagem
 - ou que não tenha uma expressão regular que o reconheça
- Na ocorrência deste erro, existem duas possibilidades
 - ou o projetista realmente esqueceu de incluir o caractere no alfabeto
 - ou realmente o usuário utilizou algum caractere que não pertence ao alfabeto da linguagem

- Tokens são padrões que podem ser especificados através de expressões regulares
- Um alfabeto determina o conjunto de caracteres válidos para a formação de cadeias, sentenças ou palavras
- Cadeias são sequências finitas de caracteres.
 Algumas operações podem ser aplicadas a alfabetos para ajudar na definição de cadeias:
 - Concatenação
 - União
 - Fechamento

Concatenação

L.M = {st | s pertence a L e t pertence a M}

União

 $L \cup M = \{s \mid s \text{ pertence a } L \text{ ou a } M\}$

Fechamento

$$L^* = \cup L_i$$
, $i = 0 ...$

Fechamento Positivo

$$L^+= \cup L_i$$
, $i=1 ...$

- Expressões regulares podem receber um nome (definição regular), formando o token de um analisador léxico
- Algumas convenções podem facilitar a formação de definições regulares
 - 1. Uma ou mais ocorrência (+)
 - 2. Zero ou mais ocorrências (*)
 - 3. Zero ou uma ocorrência (?)
 - 4. Classe de caracteres [a-z] = a | b | ... | z

São definições regulares

```
letra \rightarrow [A-Z][a-z]
dígito \rightarrow [0-9]
dígitos → dígito dígito*
identificador → letra[letra|dígito]*
fração opc \rightarrow .dígitos \epsilon
exp opc \rightarrow E[+|-|\varepsilon|dígitos|\varepsilon|
num \rightarrow digitos fração opc exp opc
delim \rightarrow ' ' | '\t' | '\n'
```

Reconhecimento de Tokens

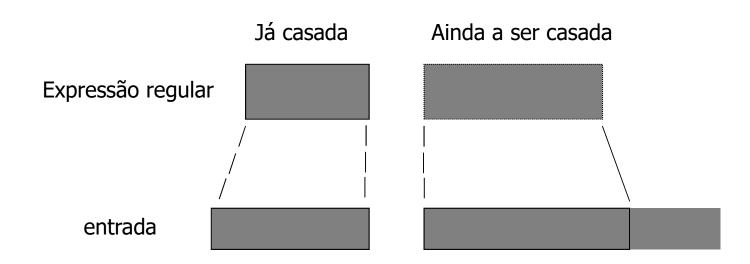
- Tokens podem ser reconhecidos através de autômatos finitos onde o estado final dispara o reconhecimento de um token específico e/ou um procedimento específico (inserir na tabela de símbolo, por exemplo).
- Normalmente constrói-se um diagrama de transição para representar o reconhecimento de tokens.

Reconhecimento de Tokens

- Como são reconhecidos os identificadores e as palavras reservadas?
- Como um compilador sabe o que é uma palavra reservada?
- O reconhecimento de identificadores e de palavras reservadas é idêntico
 - A tabela de símbolos é responsável pela identificação das palavras reservadas

Reconhecimento de Tokens

- Em geral, a tabela de símbolos é iniciada com o registro das palavras reservadas da linguagem
- O compilador sempre insere identificadores na tabela de símbolo? Isto é necessário?
 - Não, os identificadores são armazenados apenas uma vez, mas seus atributos podem ser alterados ao longo da análise de um programa
 - int a;
 - a = 10;



Intervalo

• $T \rightarrow \alpha \bullet \beta$

- Movendo Caracteres
- Se o ponto estiver à esquerda de um caractere c e se a entrada tiver c na próxima posição, o item será transportado para o outro lado e o ponto será reposicionado de acordo:

$$\blacksquare \mathsf{T} \to \alpha \bullet \mathsf{c} \beta \qquad \Rightarrow \qquad \mathsf{T} \to \alpha \mathsf{c} \bullet \beta$$

- Item de Redução:
 - $T \rightarrow \alpha\beta$ ●
- O objetivo é atingir um item de redução
 - Durante o processo de reconhecimento, cada símbolo é reconhecido na entrada
- Isto não significa que o token correto foi encontrado, pois um token mais longo ainda pode surgir

- O processo de reconhecimento continua até que não haja mais nenhuma hipótese a ser verificada.
- Assim, o *token* reconhecido mais recentemente é o *token* mais longo.
- Ponto de Partida:

$$R \to \bullet \alpha$$

 Um item no qual o ponto está a esquerda de um padrão controlado por operador tem de ser substituído por um ou mais outros itens que expressem o significado do operador.

$$\mathsf{T} \to \alpha \bullet (\mathsf{R})^* \beta \tag{1}$$

Movimentações para o ponto:

$$\mathsf{T} \to \alpha(\mathsf{R})^* \bullet \beta \tag{2}$$

$$\mathsf{T} \to \alpha(\bullet \mathsf{R})^* \beta \tag{3}$$

 Quando o ponto no item (3) é movido para o fim de R, novamente surge duas novas possibilidades de movimentação do ponto: ou esta foi a última ocorrência de R ou há outra vindo. Portanto, o item

$$\mathsf{T} \to \alpha(\mathsf{R} \bullet)^* \beta \tag{4}$$

• Deve ser substituído pelos itens (2) e (3)

- Tipos de Movimentações para os Operadores:
- Operador *

$$T \to \alpha \bullet (R)^* \beta$$

$$\Rightarrow T \to \alpha (R)^* \bullet \beta$$

$$\Rightarrow T \to \alpha (\bullet R)^* \beta$$

$$T \to \alpha(\mathsf{R} \bullet)^* \beta$$

$$\Rightarrow T \to \alpha(\mathsf{R})^* \bullet \beta$$

$$\Rightarrow T \to \alpha(\bullet \mathsf{R})^* \beta$$

Operador +

$$T \to \alpha \bullet (R)^{+} \beta$$
$$\Rightarrow T \to \alpha (\bullet R)^{+} \beta$$

$$T \to \alpha(\mathsf{R} \bullet)^{+}\beta$$

$$\Rightarrow T \to \alpha(\mathsf{R})^{+} \bullet \beta$$

$$\Rightarrow T \to \alpha(\bullet \mathsf{R})^{+}\beta$$

Operador ?

$$T \to \alpha \bullet (R)^{?} \beta$$

$$\Rightarrow T \to \alpha (R)^{?} \bullet \beta$$

$$\Rightarrow T \to \alpha (\bullet R)^{?} \beta$$

$$T \to \alpha(\mathsf{R} \bullet)^{?} \beta$$
$$\Rightarrow T \to \alpha(\mathsf{R})^{?} \bullet \beta$$

Operador |

$$T \to \alpha \bullet (R1|R2|...)\beta$$

$$\Rightarrow T \to \alpha (\bullet R1|R2|...)\beta$$

$$\Rightarrow T \to \alpha (R1|\bullet R2|...)\beta$$
...
$$T \to \alpha (R1\bullet|R2|...)\beta$$

$$\Rightarrow T \to \alpha (R1|R2|...)\beta$$

$$\Rightarrow T \to \alpha (R1|R2|...)\beta$$

$$T \to \alpha (R1|R2\bullet|...)\beta$$

$$\Rightarrow T \to \alpha (R1|R2\bullet|...)\beta$$

. . .

 Analisador Léxico para os símbolos de número inteiro e de ponto fixo

```
numero_inteiro \rightarrow [0-9]<sup>+</sup>
numero_ponto_fixo \rightarrow [0-9]*'.'[0-9]<sup>+</sup>
```

 Tentativa de reconhecer a entrada 3.1; usando a expressão regular:

```
numero_ponto_fixo \rightarrow ([0-9])*'.'([0-9])+
```

numero_ponto_fixo
$$\rightarrow \bullet([0-9])^*'.'([0-9])^+$$

- O movimento produz dois itens:
 - numero_ponto_fixo \rightarrow (\bullet [0-9])*'.'([0-9])+ (1)
 - numero_ponto_fixo \rightarrow ([0-9])*•'.'([0-9])+ (2)
- O (1) item pode ser movido sobre o 3, resultando em:
 - numero_ponto_fixo \rightarrow ([0-9]•)*'.'([0-9])+
- Mas o (2) item é descartado

numero_ponto_fixo
$$\rightarrow$$
 ([0-9] \bullet)*'.'([0-9])+

- O novo item se desenvolve em:
 - numero_ponto_fixo \rightarrow (\bullet [0-9])*'.'([0-9])+
 - numero_ponto_fixo \rightarrow ([0-9])* \bullet '.'([0-9])+
- O movimento deste conjunto sobre o caractere '.' deixa apenas um item:
 - numero_ponto_fixo → ([0-9])*'.'•([0-9])*
- Que se desenvolve em:
 - numero_ponto_fixo \rightarrow ([0-9])*'.' (\bullet [0-9])+

Exemple

```
numero_ponto_fixo \rightarrow ([0-9])*'.' (\bullet[0-9])+
```

- Este item pode ser movido sobre o 1, o que resulta em:
 - numero_ponto_fixo \rightarrow ([0-9])*'.' ([0-9]•)+
- Por sua vez se desenvolve em:
 - numero_ponto_fixo \rightarrow ([0-9])*'.' (\bullet [0-9])+
 - numero_ponto_fixo \rightarrow ([0-9])*'.' ([0-9])+• <<< reconhecido
- Observa-se que o último item é um item de redução, assim reconhecemos um símbolo e a sua classe

- A classe do símbolo e o ponto final são registrados e o algoritmo continua na captura por uma sequência mais longa
- Contudo, nenhum item pode ser movido sobre o; que segue 3.1 na entrada
 - E o processo é interrompido.
- Deste modo, retorna-se o token com a classe e a representação
 - E a posição de entrada é movida para a localização do ;

Qual análise realizar?

 Analisador Léxico para os símbolos de número inteiro e de ponto fixo

```
numero_inteiro \rightarrow [0-9]<sup>+</sup>
```

numero_ponto_fixo
$$\rightarrow$$
 [0-9]*'.'[0-9]+

3.1;

Pesquisa Concorrente

- O algoritmo anterior procurava apenas por uma classe de tokens
 - Para modificá-lo para procurar por todas as classes de tokens basta inserir todos os itens iniciais no conjunto de itens iniciais.
- Processe a entrada 3.1; com todos os símbolos

Autômatos na Análise Léxica

- O conjunto de itens considerado pelo analisador léxico em um dado momento é chamado de seu estado
- O ponto de partida é o seu estado inicial
- As transições de estado são feitas através do próximo símbolo a ser lido
 - Esta transição é chamada de função de transição
- Com isso é possível elaborar um autômato para realizar a análise léxica

Autômatos na Análise Léxica

- Para cada caractere Ch no conjunto de caracteres, calcula-se a sua transição para os estados do autômato
- O processo é repetido até que todos os estados acessíveis sejam gerados

- Para as descrições de número_inteiro e número_ponto_fixo anteriores podemos ter como estado inicial:
 - numero_inteiro \rightarrow (\bullet [0-9])⁺
 - numero_ponto_fixo \rightarrow (\bullet [0-9])*'.'([0-9])+
 - numero_ponto_fixo \rightarrow ([0-9])* \bullet '.'([0-9])+
- Chamaremos este estado de S₀.

- Consideraremos apenas três classes de caracteres:
 - Dígitos
 - Pontos decimais
 - Outros:
 - > sinais de ponto-e-vírgula, parênteses, etc
- Calcularemos as transições de S₀ com estas três classes

- Transição (S₀, dígito)
 - numero_inteiro \rightarrow (\bullet [0-9])⁺
 - numero_inteiro → ([0-9])*• <<< reconhecido</p>
 - numero_ponto_fixo \rightarrow (\bullet [0-9])*'.'([0-9])+
 - numero_ponto_fixo \rightarrow ([0-9])* \bullet '.'([0-9])+
- Chamaremos este estado de S₁.
- (S₀, dígito, S₁)

- Transição (S₀, .)
 - numero_ponto_fixo \rightarrow ([0-9])*'.'(\bullet [0-9])+
- Produzindo o estado S₂. (S₀, ., S₂)

- Transição (S₀, outros)
- Produzindo o estado S_L. (estado de lixo)
 (S₀, outros, S_I)

- Transição (S₁, dígito)
 - numero_inteiro \rightarrow (\bullet [0-9])⁺
 - numero_inteiro → ([0-9])*• <<< reconhecido</p>
 - numero_ponto_fixo \rightarrow (\bullet [0-9])*'.'([0-9])+
 - numero_ponto_fixo \rightarrow ([0-9])* \bullet '.'([0-9])+
- Que é o próprio estado S₁

- Transição (S₁, .)
 - numero_ponto_fixo \rightarrow ([0-9])*'.'(\bullet [0-9])+
- Produzindo o estado S₂. (S₁, . , S₂)
- Transição (S₁, outros)
- Produzindo o estado S_L. (estado de lixo)
 (S₁, outros, S_L)

- Transição (S₂, dígito)
 - numero_ponto_fixo \rightarrow ([0-9])*'.'(\bullet [0-9])+
 - numero_ponto_fixo \rightarrow ([0-9])*'.'([0-9])+•

<< reconhecido

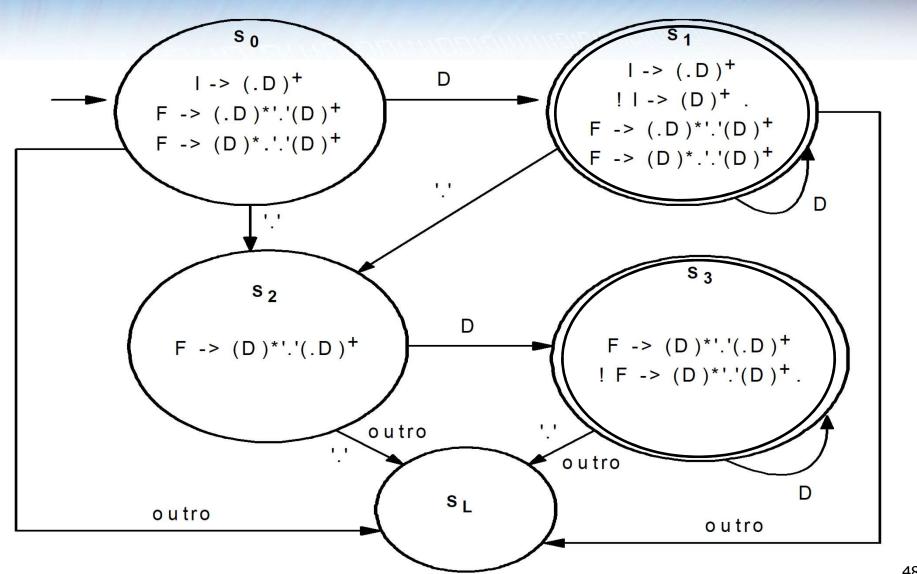
- Produzindo o estado S₃. (S₂, dígito, S₃)
- Transição (S₂, .) e (S₂, outros)
- Produzindo o estado S_L. (estado de lixo) (S₂,
 , S_L) (S₂, outros, S_L)

- Transição (S₃, dígito)
 - numero_ponto_fixo \rightarrow ([0-9])*'.'(\bullet [0-9])+
 - numero_ponto_fixo \rightarrow ([0-9])*'.'([0-9])+•

<< reconhecido

- Produzindo o estado S₃. (S₃, dígito, S₃)
- Transição (S₃, .) e (S₃, outros)
- Produzindo o estado S_L. (estado de lixo) (S₃,
 , S_L) (S₃, outros, S_L)

| | Novo estado | | | Token Reconhecido |
|------------------|----------------|----------------|----------------|----------------------|
| Estado | Ch | | | |
| | dígito | ponto | outros | |
| S_0 | S_1 | S ₂ | S _L | |
| * S ₁ | S ₁ | S ₂ | S _L | inteiro |
| S ₂ | S_3 | S _L | S _L | |
| * S ₃ | S_3 | S _L | SL | ponto_fixo |
| S _L | S_L | S _L | S _L | |



Projeto de Analisador Léxico

- 1. Definir o alfabeto
- 2. Listar os tokens necessários
- 3. Especificar os *tokens* por meio de definições regulares
- 4. Montar os autômatos para reconhecer os tokens
- 5. Implementar o analisador léxico

Projeto de Analisador Léxico

EXERCÍCIO

 Projetar um analisador léxico para uma calculadora simples com números naturais e reais, operações básicas de soma e subtração, e parênteses

Enfoques de Implementação

- Existem 3 enfoques básicos para construção de um analisador léxico:
 - 1. Utilizar um gerador automático de analisadores léxicos (tal como o compilador LEX, que gera um analisador a partir de uma especificação)
 - Escrever um analisador léxico usando uma linguagem de programação convencional que disponha de certas facilidades de E/S
 - 3. Escrever um analisador léxico usando linguagem de montagem

Enfoques de Implementação

- As alternativas de enfoque estão listadas em ordem crescente de complexidade e (infelizmente) de eficiência
- A construção via geradores é praticamente adequada quando o problema não esbarra em questões de eficiência e flexibilidade
- A construção manual é uma alternativa atraente quando a linguagem a ser tratada não for por demais complexa

Projeto de Analisador Léxico

 Exemplo - seja a cadeia 3.2 + (2 - 12.01), o analisador léxico teria como saída:

```
3.2 => número real
+ => operador de soma
( => abre parênteses
2 => número natural
- => operador de subtração
12.01=> número real
) => fecha parênteses
```

Projeto de Analisador Léxico

- Qual símbolo usar como separador de casa decimais?
- A calculadora usa representação monetária?
- A calculadora aceita espaços entre os operandos e operadores?
- O projetista é quem decide sobre as características desejáveis do compilador ou interpretador
 - Para a maioria das linguagens de programação existem algumas convenções que devem ser respeitadas

1. Definição do Alfabeto

•
$$\Sigma = \{0,1,2,3,4,5,6,7,8,9,..,(,),+,-\}$$

 OBS.: projetista deve considerar TODOS os símbolos que são necessários para formar os padrões

2. Listagem dos tokens

OPSOMA: operador de soma

OPSUB: operador de subtração

AP: abre parênteses

FP: fecha parênteses

NUM: número natural/real

 OBS.: projetista deve considerar tokens especiais e cuidar para que cada token seja uma unidade significativa para o problema

3. Especificação dos tokens com definições regulares

```
OPSOMA \rightarrow +

OPSUB \rightarrow -

AP \rightarrow (

FP \rightarrow )

NUM \rightarrow [0-9]<sup>+</sup> .? [0-9]*
```

 OBS.: cuidar para que as definições regulares reconheçam padrões claros, bem formados e definidos

4. Montar os autômatos para reconhecer cada token

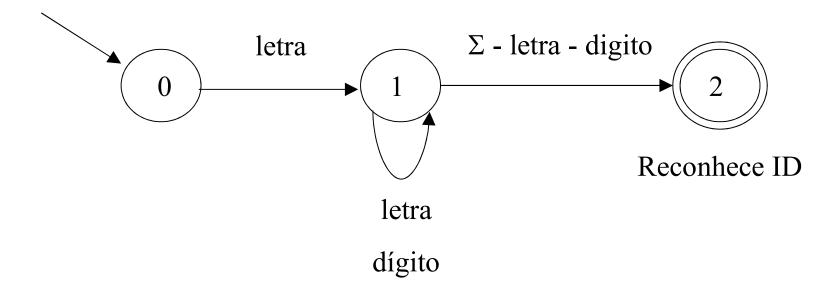
 OBS.: os autômatos reconhecem tokens individuais, mas é o conjunto dos autômatos em um único <u>autômato não-</u> <u>determinístico</u> que determina o analisador léxico de um compilador, por isto, deve ser utilizada uma numeração crescente para os estados

5. Implementar o analisador léxico

 A forma comum para implementar o autômato é através de uma tabela de transição

- Cada token listado é codificado em um número natural
- Deve haver uma variável para controlar o estado corrente do autômato e outro para indicar o estado de partida do autômato em uso
- Uma função falhar é usada para desviar o estado corrente para um outro autômato no caso de um estado não reconhecer uma letra

 Cada estado é analisado individualmente em uma estrutura do tipo switch...case



 Cada estado é analisado individualmente em uma estrutura do tipo switch...case

```
int lexico()
  while (1)
    switch (estado)
                                                                letra
      case 0: c= proximo_caracter();
        if (isalpha(c))
          estado= 1:
          adiante++;
        else
          falhar();
        break;
```

 Cada estado é analisado individualmente em uma estrutura do tipo switch...case

```
\Sigma - letra - digito
case 1: c= proximo_caracter();
  if (isalpha(c) || isdigit(c))
    estado= 1:
                                                       letra
    adiante++;
                                                      dígito
  else
    if ((c == '\n') || (c == '\t') || (c == '\b'))
      estado= 2;
    else
      falhar();
  break;
```

 Cada estado é analisado individualmente em uma estrutura do tipo switch...case

```
case 2: estado= 0;
partida= 0;
return ID;
break;
}
```



Reconhece ID

Material elaborado por:

Prof. Dr. Augusto Mendes Gomes Jr.

augusto.gomes@animaeducacao.com.br

Prof. Dr. Fernando Kakugawa

fernando.kakugawa@animaeducacao.com.br

